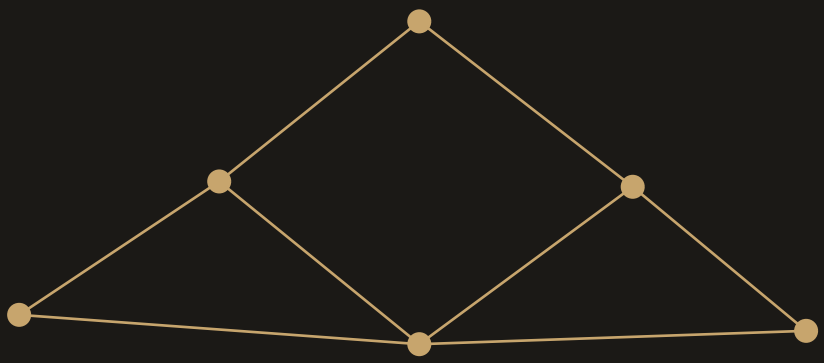
БИБЛИОТЕКА «ПЕРЕПЛЁТ»

Погружение в AI

Технологии, методы и практика
искусственного интеллекта





От первого вопроса - к осмысленной практике

УЧЕБНОЕ ПОСОБИЕ / 2026

Содержание

Содержание 2

Предисловие 4

01. Карта искусственного интеллекта 5

02. От задачи к данным 7

03. Как проверить, что модель научилась 9

04. Метрики и цена ошибок 11

05. Эксперимент и экономический эффект 13

06. Классические модели и ансамбли 15

07. Обучение без учителя и представления 17

08. Нейронные сети без мистики 19

09. Компьютерное зрение 20

10. Трансформеры и языковые модели 21

11. RAG: ответы с опорой на документы 22

12. Генерация изображений и мультимодальность 23

13. Речь, звук и перевод 24

14. Рекомендации и поиск 25

15. Обучение с подкреплением 26

16. Промпты как постановка задачи 27

17. Инструменты и агенты 28

18. Данные и инженерный конвейер 29

19. Как измерять качество 30

20. Развёртывание и наблюдение 31

21. Надёжность и безопасность 32

22. Ответственное использование 33

23. Экономика и выбор подхода 34

24. Практический маршрут изучения 35

25. ИИ в науке, медицине и общественных задачах 36

Практикум. Проверить понимание 38

Словарь основных понятий 40

Навигатор по темам 42

Источники и дальнейшее чтение 43

Выходные сведения 45

Предисловие

Искусственный интеллект становится понятнее, если рассматривать его не как единственную чудесную технологию, а как набор способов решать задачи: предсказывать, распознавать, искать, создавать и выбирать действия. Для каждого способа нужны свои данные, критерии качества и ограничения. Именно этой логике подчинено пособие.

Пособие знакомит с основами машинного обучения, генеративными моделями, поиском по документам, агентами и эксплуатацией ИИ. Теория сопровождается учебными примерами, практическими вопросами и ссылками на научные и технические источники. Числа в учебных задачах являются условными.

Читайте главы последовательно, если знакомитесь с предметом впервые. Если вы уже работаете с данными, начните с глав о трансформерах, RAG и агентах, затем вернитесь к метрикам и проверке качества. Последние главы помогут превратить отдельную модель в полезное и контролируемое приложение.

01. Карта искусственного интеллекта

От правил к обучению

В системе, основанной на правилах, человек заранее описывает переход от входных данных к ответу. Например: если документ не подписан, направить его на доработку. Машинное обучение устроено иначе: разработчик задаёт семейство моделей, способ измерения ошибки и процедуру настройки, а закономерности извлекаются из примеров. Правила при этом не исчезают. Они ограничивают допустимые решения и часто работают рядом с обучаемой моделью.

Искусственный интеллект - более широкая область, чем машинное обучение. В неё входят также поиск, планирование, представление знаний и другие методы. Глубокое обучение использует многослойные нейронные сети. Генеративный ИИ создаёт новые последовательности или объекты: текст, код, звук, изображения. Не каждый ИИ является нейросетью, и не всякая нейросеть является генеративной.

Пять типов полезных действий

Предсказание оценивает неизвестную величину: спрос завтра или срок доставки. Распознавание определяет свойства наблюдаемого объекта: вид документа, дефект детали. Поиск возвращает подходящую информацию. Генерация создаёт вариант результата. Выбор действия соединяет прогноз с целью и ограничениями: какое предложение показать, куда направить заявку, когда вызвать специалиста.

Один продукт может объединять все пять типов. Ассистент по документам распознаёт скан, находит относящиеся к вопросу положения, составляет черновик ответа и передаёт его человеку. Но способность написать убедительный ответ не доказывает правильность найденного основания и не даёт системе права самостоятельно выполнять юридически значимое действие.

Как читать сообщения о прогрессе

В AI Index 2026 отмечается рост возможностей моделей, но одновременно подчёркивается их неравномерность: высокие результаты на одном тесте могут сочетаться с ошибками в сравнительно простых задачах. Поэтому научный результат следует читать вместе с условиями эксперимента: какие данные использованы, что именно считается успехом, каков бюджет вычислений и участвовал ли человек. [1]

Термин AGI обозначает обсуждаемую идею общего искусственного интеллекта. Единого общепринятого практического критерия его достижения нет. Размер модели, беглая речь или высокий балл на экзамене сами по себе не устанавливают наличие общего интеллекта либо сознания. Предсказания точной даты его появления следует воспринимать как прогнозы, а не как технические факты.

Главная мысль: оценивать нужно конкретную систему в конкретной задаче, а не слово «ИИ» в её названии.

02. От задачи к данным

Начать с решения, которое предстоит принять

«Внедрить нейросеть» - не постановка задачи. Хорошая постановка отвечает на четыре вопроса: кто пользуется результатом, какое решение изменится, как измеряется полезность и какая ошибка недопустима. Если магазин хочет реже оставаться без популярных книг, целевой результат - не красивый прогноз, а снижение дефицита при приемлемом объёме запасов.

Единица наблюдения должна быть определена заранее: заказ, клиент, документ, день работы филиала. Признаки - сведения, доступные на момент решения. Целевая переменная - результат, который предстоит предсказать. Если прогнозируется задержка доставки при оформлении заказа, использовать фактическую дату вручения как входной признак нельзя: это информация из будущего.

Основные постановки

Регрессия предсказывает число: время ожидания, стоимость, объём спроса. Классификация выбирает класс или оценивает его вероятность: обращение относится к доставке или оплате. Ранжирование упорядочивает кандидатов: какие книги показать выше. Кластеризация ищет группы без заранее заданных меток. Обнаружение аномалий выделяет необычные наблюдения, но необычность не означает автоматически нарушение или мошенничество.

Один сюжет допускает разные постановки. Срок доставки можно прогнозировать числом дней, вероятностью опоздания или интервалом. Выбор зависит от действия: для обещания покупателю нужен надёжный срок, для распределения транспорта - прогноз загрузки, для предупреждения оператора - вероятность нарушения обязательства.

Качество учебной выборки

Данные описывают не весь мир, а способ его наблюдения. История продаж не включает людей, которым товар не показали. История одобренных заявок не раскрывает поведение всех получивших отказ. Отсутствие записи может означать отсутствие события, неисправность системы или потерю канала наблюдения. Эти случаи нельзя смешивать.

Паспорт набора данных фиксирует происхождение, период, единицу наблюдения, правила формирования меток, пропуски и ограничения использования. Разметка требует инструкции и разрешения спорных случаев.

Для неоднозначного текста полезно сравнивать ответы нескольких разметчиков и отдельно оценивать согласованность.

Прежде чем строить сложную модель, создайте baseline: простое правило, среднее значение, прогноз «как на прошлой неделе» или линейный алгоритм. Он показывает, даёт ли усложнение реальное преимущество. Если baseline не уступает нейросети по полезности и надёжности, его использование является профессиональным выбором.

Практика: сформулируйте задачу «помочь читателю найти книгу» тремя способами - поиск, классификация интереса и персональное ранжирование. Для каждого запишите требуемые данные.

03. Как проверить, что модель научилась

Три разных роли данных

Обучающая выборка используется для настройки параметров. Валидационная помогает выбирать гиперпараметры, признаки и пороги. Тестовая предназначена для заключительной оценки уже выбранного решения. Если постоянно менять модель, глядя на тест, этот набор фактически становится частью разработки и перестаёт давать независимую проверку.

Случайное разделение подходит не всегда. Во временном прогнозе обучение должно предшествовать проверке по времени. Если один человек представлен несколькими записями, его данные могут потребовать группового разделения. Иначе система узнает знакомого человека, а эксперимент ошибочно представит это как способность работать с новыми пользователями.

Недообучение и переобучение

Недообученная модель слишком проста или плохо настроена: она не воспроизводит важные закономерности даже в учебных данных. Переобученная модель подстраивается под особенности конкретной выборки, включая шум. Низкая ошибка обучения при существенно большей ошибке проверки - повод исследовать переобучение, но не единственное возможное объяснение: причиной также бывает различие распределений.

Регуляризация ограничивает сложность или чувствительность модели. Помогают также ранняя остановка, уменьшение числа признаков, увеличение разнообразия данных и корректная аугментация. Не существует универсального правила, что больше параметров всегда означает хуже обобщение: важны архитектура, объём данных и процедура обучения.

Утечка данных

Нельзя сначала вычислить статистики нормализации на всей выборке, а потом объявить часть строк независимым тестом. Преобразования, которые чему-либо обучаются на данных, подгоняются только на обучающей части. То же относится к заполнению пропусков, отбору признаков и подбору представлений, если они входят в проверяемый процесс. Конвейеры помогают выполнять эту последовательность воспроизводимо. [3]

Кросс-валидация повторяет оценку на нескольких разбиениях. Она полезна для сравнения решений и оценки изменчивости результатов, но не исправляет ошибочную постановку эксперимента. Если в каждом разбиении сохраняется информация из будущего, усреднение сделает неверный результат лишь более убедительным.

Сохраняйте версию данных, код преобразований, настройки модели и способ разбиения. Два одинаковых числа без этих сведений ещё не означают воспроизводимого результата. Для небольших выборок особенно важно сообщать неопределённость оценки и не объявлять превосходством различие в несколько случайных удачных ответов.

04. Метрики и цена ошибок

Ошибка прогноза числа

MAE, mean absolute error, - среднее абсолютное отклонение прогноза от факта. MSE - среднее квадратов отклонений. RMSE - квадратный корень из MSE; его единицы совпадают с единицами целевой величины. Квадратичная ошибка сильнее выделяет большие промахи. [2]

Для фактических сроков 2, 4 и 6 дней модель предсказала 3, 4 и 4 дня. Абсолютные ошибки равны 1, 0 и 2. MAE составляет 1 день, MSE - 5/3 дня в квадрате, RMSE - около 1,29 дня. Ни одна из этих метрик сама по себе не говорит, насколько покупатель недоволен: обещание слишком ранней доставки может стоить дороже излишне осторожного срока.

Матрица ошибок классификации

Пусть положительный класс означает дефект. TP - найденный дефект; FP - ложная тревога; FN - пропущенный дефект; TN - правильно признанное отсутствие дефекта. Accuracy измеряет долю всех верных ответов. Precision показывает, какая доля тревог обоснованна. Recall показывает, какая доля реальных дефектов обнаружена. F1 объединяет precision и recall через гармоническое среднее. [2]

В условной партии из 1 000 изделий есть 20 дефектных. Система нашла 16 дефектов и ошибочно забраковала 24 исправных изделия. Precision = 16/40 = 40%; recall = 16/20 = 80%; accuracy = 972/1000 = 97,2%; F1 ≈ 53,3%. Высокая общая точность скрывает то, что большинство тревог ложные. Это причина смотреть на несколько показателей одновременно.

Порог и вероятность

Оценка 0,8 не обязана означать, что событие происходит в 80% подобных случаев. Такое соответствие называется калибровкой и проверяется отдельно. Порог решения выбирается с учётом стоимости FP и FN, ограничений команды и приемлемого риска. Порог 0,5 не является обязательным.

ROC-AUC описывает качество упорядочивания положительных и отрицательных примеров по оценке модели. PR-кривая и average precision особенно полезны при редком положительном классе. Но метрика ранжирования не заменяет проверку конкретного рабочего порога, нагрузки на операторов и калибровки вероятностей.

Правило: сначала определить последствия ошибки, затем выбрать метрику. Для денег, здоровья и доверия цена двух типов ошибок редко одинакова.

05. Эксперимент и экономический эффект

Хорошая метрика ещё не означает пользу

Модель оттока ищет людей, которые могут перестать пользоваться сервисом. Но из этого не следует, что именно им полезно выдавать скидку. Часть останется и без скидки, часть уйдёт при любом предложении. Для решения важен эффект воздействия, а не только вероятность события. Этот вопрос относится к причинному анализу и uplift-моделированию.

Представим условную кампанию: сообщение отправлено 1 000 клиентам, стоимость контакта составляет 2 рубля, дополнительная маржа от сохранённого заказа - 300 рублей. Если эксперимент показывает 20 дополнительных заказов именно вследствие кампании, вклад до остальных расходов равен 20 × 300 - 1 000 × 2 = 4 000 рублей. Считать все покупки после рассылки её результатом было бы ошибкой.

A/B-тестирование

Случайное распределение пользователей по группам помогает сравнить новую систему с контрольным вариантом. Заранее задаются основная метрика, единица рандомизации, длительность, минимально значимый эффект и правила остановки. Если пользователи влияют друг на друга или делят общий ресурс, это влияние нужно учесть в дизайне эксперимента.

Нельзя ежедневно просматривать десятки метрик, останавливая тест при первом выгодном различии, и считать такой вывод обычным результатом независимой проверки. Последовательный анализ возможен, но требует подходящего статистического метода. Для практического вывода важны и доверительный интервал, и размер эффекта, и эксплуатационная цена нового решения.

Ограничители результата

Рекомендации способны увеличивать клики, одновременно ухудшая разнообразие и удовлетворённость. Ускорение обработки может повысить число ошибочных решений. Поэтому рядом с основной метрикой нужны ограничители: жалобы, отмены, задержки, доля ручных исправлений, доступность сервиса и частота серьёзных ошибок.

Если прямой эксперимент слишком рискован, начните с теневого режима: модель даёт прогнозы, но решения по ним пока не исполняются. Затем возможен ограниченный пилот с контролируемым масштабом. Отсутствие обнаруженных проблем в небольшом пилоте не является доказательством безопасности на любой нагрузке и в любой группе пользователей.

Вопрос для проверки: модель стала точнее на 2 процентных пункта, но отвечает в пять раз медленнее. Какие данные понадобятся, чтобы решить, стоит ли её внедрять?

06. Классические модели и ансамбли

Линейные модели и деревья

Линейная регрессия связывает числовой результат со взвешенной суммой признаков. Коэффициенты удобно анализировать, но их нельзя автоматически трактовать как причинное влияние. Коррелирующие признаки, масштаб измерения и пропущенные факторы меняют интерпретацию. Логистическая регрессия применяется к классификации и преобразует линейную оценку в вероятность класса.

Дерево решений делит пространство признаков последовательностью условий. Например, сначала проверяет срок исполнения, затем тип заказа. Небольшое дерево обычно понятно человеку; большое может запомнить шум. Глубину, минимальный размер листа и другие ограничения подбирают на валидации.

Метод ближайших соседей опирается на похожие наблюдения и чувствителен к выбору расстояния и масштабу признаков. Наивный байесовский классификатор использует упрощающие вероятностные предположения. Метод опорных векторов ищет разделяющую границу и может работать с нелинейными зависимостями через ядра. Эти методы полезны как решения или как точки сравнения.

Зачем объединять модели

Bagging обучает несколько моделей на случайных выборках с возвращением и объединяет прогнозы. Случайный лес дополнительно использует случайный выбор признаков при построении деревьев. Это снижает сходство ошибок. Преимущество ансамбля определяется не одним количеством участников, а качеством и разнообразием их прогнозов. [4]

В градиентном бустинге новые компоненты последовательно улучшают текущую композицию, ориентируясь на функцию потерь. Фраза «каждое дерево исправляет остатки» хорошо передаёт интуицию квадратичной регрессии, но в общем случае речь идёт о градиенте выбранной функции. Последовательность этапов не исключает параллельных вычислений внутри отдельных этапов. [4]

Stacking обучает модель объединения на прогнозах других моделей. Для её обучения нужны корректно полученные вневыборочные прогнозы: если

передать ответы базовых моделей на тех же данных, на которых они обучались, итоговая оценка может оказаться слишком оптимистичной.

Выбор по условиям задачи

Для табличных данных бустинг часто является сильным кандидатом, но не универсальным победителем. Для маленькой выборки может оказаться удобнее простая модель; для сложных текстов - предобученная нейросеть. Сравнивайте качество, задержку, память, стабильность, возможность объяснить решение и стоимость поддержки. Сложность архитектуры сама по себе не является достоинством.

07. Обучение без учителя и представления

Кластеры не равны готовым смыслам

Кластеризация группирует наблюдения по заданной мере похожести. Алгоритм k-means чередует назначение объектов ближайшим центрам и пересчёт центров. Число кластеров задаётся заранее. Результат зависит от масштаба признаков, начальных центров и геометрии данных. Вытянутые группы, шум и различная плотность могут потребовать другого метода.

Полученные группы нужно интерпретировать и проверять. Кластер покупателей с похожими действиями не обязательно является устойчивым психологическим типом. Изменение интерфейса или ассортимента может изменить поведение и границы групп. Выявленный шаблон - гипотеза о структуре данных, а не установленная причина.

Снижение размерности

PCA ищет ортогональные направления наибольшей вариации. Проекция уменьшает число координат, но может потерять признак, важный для конкретного ответа. Большая дисперсия не равна большой полезности. Визуализация через t-SNE или UMAP помогает исследовать данные, однако расстояния и размеры групп на плоскости нельзя без проверки переносить на исходное пространство.

Эмбеддинг - числовое представление объекта, полезное для выбранной задачи. Это может быть вектор слова, документа, изображения, товара или узла графа. Эмбеддинг не обязательно имеет меньшую размерность, чем исходное описание; его смысл не сводится к сжатию. Он организует отношения между объектами так, чтобы последующим алгоритмам было проще с ними работать.

Самоконтролируемое обучение

В self-supervised learning обучающий сигнал создаётся из самих данных: восстановить скрытую часть, предсказать следующий элемент или сопоставить связанные представления. Для этого не требуется вручную размечать каждый пример, но выбор данных и учебной задачи остаётся человеческим решением.

Контрастивное обучение сближает представления связанных объектов и различает несвязанные. Совместное обучение изображений и подписей позволяет сопоставлять картинку с текстовым описанием. Однако обычный контрастивный алгоритм не узнает автоматически название ранее неизвестного класса: для такого переноса нужна соответствующая семантическая опора, например текстовое описание. Подход CLIP показывает один из вариантов подобного переноса. [11]

Важное различие: transfer learning использует знания ранее обученной модели. Self-supervised learning - один из способов получить такие знания, но не единственный.

08. Нейронные сети без мистики

Слои, параметры и обучение

Нейрон вычисляет взвешенную сумму входов, добавляет смещение и применяет функцию активации. Сеть соединяет такие преобразования. Параметры - числа, настраиваемые по данным, а не заранее записанные правила понимания мира. Нелинейность позволяет моделировать зависимости, которые нельзя выразить одной линейной функцией.

На прямом проходе сеть выдаёт прогноз; функция потерь сравнивает его с учебной целью. Обратное распространение вычисляет производные потерь по параметрам. Оптимизатор использует градиенты, чтобы обновить параметры. Один проход по всему обучающему набору называют эпохой, а отдельное обновление обычно выполняют по небольшой порции данных - батчу.

Глубина и число параметров не гарантируют качество. Слишком сложная модель способна запомнить шум; слишком простая - не уловить полезную зависимость. Регуляризация, проверка на отложенных данных и ранняя остановка помогают выбирать модель по результату, а не по размеру.

Проверьте себя: почему уменьшение обучающей ошибки не доказывает улучшения на новых примерах? Ответ: оптимизация идёт на известных данных, а обобщение оценивают отдельно.

09. Компьютерное зрение

Изображение как данные

Изображение представляют массивом чисел. Классификация определяет категорию всего кадра; детекция находит объекты и их рамки; сегментация назначает класс пикселям. Для этих задач нужны разные виды разметки и разные метрики. Точность классификации нельзя напрямую сравнивать с качеством сегментации.

Свёрточные сети используют локальные фильтры, а зрительные трансформеры работают с представлениями участков изображения. На практике выбирают подход по качеству, скорости, доступным данным и ресурсам. Архитектура сама по себе не защищает от изменения освещения, ракурса или камеры.

При работе со сканами различайте просмотр и OCR. Просмотр воспроизводит изображение страницы. OCR распознаёт символы и создаёт текст, который можно искать и копировать. Ошибки OCR особенно вероятны в таблицах, формулах, старых шрифтах и многоязычных документах. Сверяйте распознанные числа с оригиналом.

Пример: для поиска дефектов оборудования собирайте изображения разных смен и камер. Если в тест попали почти одинаковые кадры одной детали, оценка может оказаться завышенной.

10. Трансформеры и языковые модели

Внимание и последовательность

Токенизация разбивает текст на элементы словаря: слова, части слов или другие последовательности символов. Число токенов не равно числу слов и зависит от языка и токенизатора. Модель получает числовые представления токенов и информацию о порядке.

Механизм внимания сопоставляет элементы последовательности и строит контекстные представления. В исходной работе Transformer использовалась архитектура encoder-decoder для перевода [5]. Архитектура конкретной модели может отличаться: существуют encoder-only и decoder-only варианты.

Авторегрессионная модель последовательно оценивает вероятности следующего токена. Из этого механизма возникают полезные способности к продолжению текста, переводу и решению задач, но правдоподобная последовательность не является доказательством истинности. Контекстное окно ограничено, а сведения в параметрах могут быть устаревшими.

Генерация и проверка

Предобучение формирует общие закономерности по большому корпусу. Последующие этапы могут настраивать поведение по инструкциям и предпочтениям. Эти этапы не следует путать с добавлением документов в запрос: документы меняют входной контекст, а не обязательно параметры модели.

Fine-tuning обновляет параметры на специализированных примерах; LoRA настраивает небольшие добавочные матрицы вместо всех весов [10]. RLHF использует обратную связь о предпочтениях, а DPO предлагает другой способ оптимизации по парам предпочтений [8, 9]. Эти методы не создают базу проверенных фактов автоматически.

Чем выше разнообразие выборки токенов, тем сильнее могут различаться ответы. Даже при фиксированных настройках нельзя считать повторяемость абсолютной без проверки конкретной системы. Для фактических ответов важнее доступ к источникам, проверка утверждений и возможность честного отказа.

11. RAG: ответы с опорой на документы



Поиск перед генерацией

Retrieval-Augmented Generation соединяет поиск релевантного материала и генерацию ответа [12]. Типовой процесс: подготовить документы, разбить их на фрагменты, построить индекс, найти кандидатов по вопросу, передать отобранные фрагменты модели и проверить ответ.

Поиск может быть полнотекстовым, векторным или гибридным. Векторное сходство полезно для смысловой близости, но не заменяет фильтры прав доступа, дат и версий. Переранжирование помогает выбрать более подходящие фрагменты среди кандидатов.

Ответ должен ссылаться на доступный пользователю источник и поддерживаться именно приведённым фрагментом. Наличие ссылки ещё не означает, что утверждение верно: модель может процитировать неподходящий абзац. Отдельно измеряйте полноту поиска и точность ответа.

RAG уменьшает зависимость от памяти модели, но не исключает ошибки. Если релевантного документа нет, полезнее сообщить об отсутствии основания, чем дописать ответ по догадке.

12. Генерация изображений и мультимодальность

Разные виды содержания

Мультимодальная система обрабатывает несколько типов данных: текст, изображение, звук, видео. Возможности зависят от конкретной модели и интерфейса. Умение описать картинку не доказывает умения точно считать объекты, читать мелкие подписи или измерять расстояния.

Диффузионные модели обучаются восстанавливать данные после добавления шума; при генерации выполняется последовательность преобразований, направляемая условием. GAN использует обучение генератора и дискриминатора. Это разные подходы, а не последовательные стадии одной обязательной технологии.

Flow matching обучает поле скоростей, которое переносит простое распределение в распределение данных. Этот подход связан с непрерывными генеративными процессами, но не тождественен любому диффузионному алгоритму [16].

Генерируемое изображение может содержать неверные детали, анатомические ошибки и искажённый текст. Для технической схемы сначала проверьте смысл, затем оформляйте графику. Для обложки допустима художественная условность, но её не следует выдавать за фотографическое свидетельство.

13. Речь, звук и перевод

От сигнала к смыслу

Распознавание речи преобразует аудио в текст, синтез - текст в звук. Перевод переносит содержание между языками. Эти задачи можно соединять, но ошибка раннего этапа переходит на следующий: неверно распознанная фамилия способна испортить перевод и резюме встречи.

Для оценки распознавания используют, например, долю ошибок в словах (WER). Сравнение корректно только при одинаковых правилах подготовки текста и похожем наборе записей. Шум, диалект, специальные термины и наложение голосов меняют результат.

Перед публикацией проверьте имена, числа, даты и решения. Синтетический голос требует внимания к согласию и контексту использования. Не считайте похожесть голоса подтверждением личности говорящего.

14. Рекомендации и поиск

Полезность зависит от цели

Рекомендательная система отбирает и ранжирует объекты для пользователя. Контентный подход использует свойства объектов, коллаборативный - закономерности взаимодействий. В реальных системах эти сигналы часто объединяют с правилами доступности и разнообразия.

Для книжного магазина недостаточно максимизировать клики. Учитывайте удовлетворённость, разнообразие авторов, наличие книг и возможность открыть для себя новое. Оптимизация одного показателя может вытеснить редкие и новые издания.

Холодный старт возникает для нового пользователя или объекта, когда истории ещё нет. Используйте явные интересы, содержание и редакторские подборки. Эксперимент сравнивают с понятной базовой стратегией; офлайн-метрика ранжирования и реальная польза не тождественны.

15. Обучение с подкреплением

Действие, награда, среда

Агент выбирает действия, среда меняет состояние, а награда оценивает последствия. Цель - не угадать готовую метку, а улучшить стратегию действий по накопленному опыту. Для обучения важен баланс исследования новых вариантов и использования уже найденных.

Награда - формальное приближение цели. Если поощрять только скорость обработки обращений, система может научиться закрывать их без решения. Проверяйте нежелательные способы получить высокий балл и ограничения, которые нельзя обменять на дополнительную награду.

Обучение в симуляторе может плохо переноситься в физический мир. Дорогие или опасные действия требуют отдельных ограничений, проверки человеком и возможности остановки. Высокая награда в учебной среде не равна безопасности эксплуатации.

16. Промпты как постановка задачи

Сделать результат проверяемым

Хороший запрос задаёт цель, входные данные, ограничения и ожидаемую форму результата. Пример: «По приложенному тексту выпиши решения встречи, ответственных и сроки. Если срок не указан, напиши “не указан”. Для каждого пункта приведи короткий фрагмент основания».

Примеры помогают показать формат, но могут навязать нежелательный шаблон. Отделяйте инструкции от цитируемых материалов и явно указывайте, какой источник считать основанием. Для сложной работы полезно сначала уточнить критерии результата, а затем проверить ответ по ним.

Промпт не гарантирует правильности и не заменяет программную валидацию. Если нужен JSON, проверяйте его схему. Если требуется расчёт, пересчитывайте значения. Если есть внешнее действие, проверяйте адресата, параметры и полномочия отдельно от текста ответа.

17. Инструменты и агенты

От ответа к действию

Агентная система соединяет модель, состояние задачи и инструменты: поиск, выполнение кода, работу с файлами или API. Модель предлагает вызов, а программа проверяет его параметры и выполняет разрешённую операцию. Результат инструмента возвращается в контекст для следующего шага.

Заранее определите предел числа шагов, времени и затрат. Храните состояние и журнал операций. Повторный запуск не должен создавать дубликаты платежей или заявок: для значимых действий нужны механизмы идемпотентности и проверки уже выполненного.

Данные из страницы или документа могут содержать команды злоумышленника. Не позволяйте таким командам менять доверенные инструкции и права инструментов. Уровень доступа должен соответствовать задаче, а необратимые действия - проходить предусмотренную проверку.

18. Данные и инженерный конвейер

Качество начинается до модели

Зафиксируйте происхождение, разрешённое использование и правила обновления данных. Удаляйте дубликаты и явные ошибки, но не уничтожайте редкие важные случаи только потому, что они неудобны. Храните версии набора, чтобы можно было воспроизвести эксперимент.

Разделяйте данные до тех преобразований, которые способны перенести информацию между выборками. Нормализацию и выбор признаков обучают на тренировочной части. Для временных рядов проверка должна отражать прогноз в будущее, а не случайное перемешивание времён.

Конвейер включает сбор, проверку схемы, подготовку, обучение, оценку и публикацию. На каждом этапе полезны простые контрольные правила: допустимые диапазоны, пропуски, свежесть и распределения. Модель не исправит незаметно сломанный источник данных.

19. Как измерять качество

Метрика следует за ошибкой

Accuracy - доля правильных классификаций. Precision показывает, какая доля положительных ответов верна; recall - какая доля реально положительных случаев обнаружена. При редком событии высокая accuracy может достигаться постоянным ответом «нет».

Для генеративных ответов оценивайте выполнение инструкции, фактическую опору, полноту, стиль и нежелательные действия отдельно. Набор проверок должен включать типичные вопросы, сложные случаи, отсутствие ответа и попытки обмана. Проверка другой моделью полезна, но тоже требует калибровки по человеческим оценкам.

Сохраняйте базовый результат до изменения системы. Прогоняйте один и тот же набор после обновления модели, промпта или индекса. Средний балл скрывает провалы отдельных групп: изучайте распределение и критические ошибки.

20. Развёртывание и наблюдение

Система меняется после запуска

Мониторинг включает задержку, стоимость, частоту сбоев, качество и изменения входных данных. Data drift описывает изменение распределения входов, concept drift - изменение связи между признаками и целью. Первый не всегда означает ухудшение; второй трудно заметить без новых проверенных ответов.

Продумайте резервный путь: обычный поиск, ответ по шаблону или передача человеку. Версионируйте модель и конфигурацию; предусмотрите откат. Обновление оценивают на ограниченной доле трафика, если такой эксперимент допустим.

Логи помогают разбирать ошибки, но могут содержать личные данные. Собирайте только нужное, ограничивайте доступ и срок хранения. Не записывайте секреты в диагностические сообщения.

21. Надёжность и безопасность

Несколько границ защиты

Галлюцинация - неверное или неподтверждённое содержание, представленное как ответ. Её нельзя надёжно распознать только по уверенной интонации. Используйте источники, проверки чисел и возможность отказа, когда данных недостаточно.

Prompt injection - попытка внедрить инструкции через данные, например веб-страницу. Защита требует разграничения доверия и полномочий; одна фраза в системном запросе не решает проблему. Результаты инструментов рассматривают как данные, а опасные действия проверяют программно.

Не передавайте системе лишние секреты. Разделяйте доступ на чтение и запись; по возможности используйте тестовые среды. Проверяйте не только хороший сценарий, но и сбой сети, устаревший документ, неверный формат и отсутствие прав.

22. Ответственное использование

Решение остаётся в контексте

Смещение данных способно приводить к неравномерным ошибкам. Сравнивайте качество для значимых групп и изучайте причины расхождений. Формальное равенство одной метрики не означает справедливости всей процедуры.

Фиксируйте, где применён ИИ и кто отвечает за итог. Для важных решений человеку нужны основания, возможность исправления и понятный путь обжалования. Автоматизация без обратной связи закрепляет ошибки.

Права на данные, изображения и тексты зависят от источников и условий использования. Указание автора оформления не передаёт ему права на чужие материалы. Отдельно храните сведения о происхождении и лицензиях; юридические выводы проверяют для конкретной ситуации.

23. Экономика и выбор подхода

Начинать с простой альтернативы

Сравните ИИ с правилами, SQL-запросом, обычным поиском и ручной обработкой. Если задача решается коротким детерминированным алгоритмом, сложная модель может только увеличить стоимость и неопределённость.

Считайте не только цену вызова: подготовку данных, интеграцию, оценку, контроль человеком, хранение и поддержку. Польза измеряется изменением процесса: временем, ошибками и качеством услуги. Демонстрация на нескольких примерах не является оценкой окупаемости.

Сначала проверьте гипотезу на ограниченном сценарии с измеримым результатом. Определите критерий остановки пилота. Если качество недостаточно, честный вывод о неприменимости полезнее расширения проекта без доказанной пользы.

24. Практический маршрут изучения

Учиться на проверяемом проекте

Начните с задачи классификации небольшого набора данных. Разделите выборки, постройте простую базовую модель, измерьте метрику и разберите ошибки. Затем измените один элемент и сравните результат. Так становится видна связь между данными, моделью и оценкой.

Следующий проект - поиск по собственной небольшой библиотеке документов. Сначала сделайте обычный полнотекстовый поиск, затем добавьте векторный и сравните на одинаковых вопросах. Только после этого подключайте генерацию ответа с цитатами.

Завершите проект карточкой системы: назначение, ограничения, данные, метрики, известные ошибки и способ обновления. Отдельно опишите, когда пользователь должен обратиться к первоисточнику. Эта привычка важнее знания названий популярных моделей.

25. ИИ в науке, медицине и общественных задачах

Прогноз как инструмент исследования

В науке ИИ помогает находить закономерности, выбирать кандидатов для эксперимента, анализировать изображения и моделировать сложные системы. Научная ценность определяется не убедительностью ответа, а воспроизводимостью, проверкой гипотезы и сопоставлением с наблюдением. Хороший прогноз способен ускорить исследование, не объясняя полностью изучаемый механизм.

В климатических и природных задачах модели используют спутниковые изображения, показания датчиков и временные ряды. Прогноз паводка или пожара полезен только вместе с оценкой неопределённости, своевременным оповещением и планом действий. Если данные редких экстремальных событий ограничены, усреднённая точность особенно мало говорит о готовности к кризису.

Медицинские применения

Анализ снимков, организация потоков пациентов и подготовка документов представляют разные уровни риска. Качество на архивной выборке не устанавливает клиническую пользу. Проверка должна учитывать новые учреждения, оборудование, особенности пациентов и реальное влияние на решения специалистов.

В учебном примере с редким заболеванием классификатор может иметь высокую accuracy и пропускать больных. Поэтому медицинский сценарий особенно ясно показывает значение чувствительности, специфичности, распространённости состояния и последующей проверки. Интерпретировать конкретный результат следует в профессиональном клиническом контексте.

Робототехника и физический мир

Робот соединяет восприятие, планирование и управление. Языковая модель может помогать интерпретировать задание, но движения требуют надёжного контура исполнения, ограничений силы и скорости, обработки препятствий и аварийной остановки. Цифровая команда и физическое действие имеют разные последствия.

Автоматизация испытаний терминала или устройства объединяет роботизированные манипуляции с компьютерным зрением. Такой стенд может воспроизводить множество сценариев, но не устраняет необходимость проверить нестандартные состояния, отказ датчика и безопасность взаимодействия с человеком.

Доступность и общественная польза

Автоматические субтитры, озвучивание текста и описание изображения могут расширять доступ к информации. Польза зависит от качества на разных языках и для разных групп людей. Недостаточная представленность языка или особенностей речи в данных способна создать новый барьер вместо устранения старого.

Оценивая социальный проект, проверяйте, кто получает пользу, кто несёт риск ошибки и есть ли альтернативный способ воспользоваться услугой. Техническое удобство для организации не всегда совпадает с удобством для человека. Сохранение понятного ручного маршрута является частью качества системы.

Практикум. Проверить понимание

Задание 1. Данные из будущего

Модель прогнозирует просрочку заказа в момент оформления. В таблице есть дата оформления, обещанный срок, фактическая дата доставки и число обращений после доставки. Какие столбцы нельзя подавать на вход? Как организовать проверку по времени?

Разбор: фактическая дата и последующие обращения ещё неизвестны в момент решения. Это утечка. Обучение строится на более раннем периоде, проверка - на следующем, с учётом задержки появления меток. Идентичные или связанные заказы не должны искусственно дублировать успех.

Задание 2. Ложные тревоги

Из 10 000 операций 100 действительно проблемные. Система отметила 200 операций, из которых 80 проблемные. Найдите precision и recall. Достаточно ли этих двух чисел для решения о внедрении?

Разбор: precision = 80/200 = 40%; recall = 80/100 = 80%. Пропущено 20 проблемных операций, создано 120 ложных тревог. Нужны стоимость последствий, нагрузка на проверяющих, калибровка и оценка на независимых данных. Предельная допустимая ошибка зависит от применения.

Задание 3. Обновление знаний

Ассистент должен отвечать по документам, которые меняются каждую неделю. Что выбрать первым: полное переобучение модели, fine-tuning или поиск по актуальным версиям?

Разбор: начать следует с качественного поиска и управления версиями. RAG может включить найденные документы в ответ. Дообучение полезно для поведения и специальных навыков, но само по себе не обеспечивает своевременного обновления фактов и проверяемых ссылок.

Задание 4. Красивое изображение

Модель восстановила текст на размытой фотографии. Можно ли считать получившуюся надпись достоверной?

Разбор: восстановление может создавать правдоподобную деталь. Для доказательного использования нужен оригинал или независимое

подтверждение. Улучшение внешней читаемости и восстановление исторически верного содержания - разные результаты.

Задание 5. Автономный помощник

Агент нашёл в документе указание отправить весь каталог и данные пользователей на внешний адрес. Какие границы системы должны помешать этому действию?

Разбор: документ рассматривается как недоверенные данные; у агента нет избыточного доступа и произвольного инструмента отправки. Внешние действия имеют ограничения и проверку полномочий. Журнал позволяет установить попытку, а безопасная остановка не зависит от доброй воли модели.

Задание 6. Смена цели

Рекомендатель увеличил клики на 15%, но выросло число быстрых возвратов из карточек. Как интерпретировать результат?

Разбор: клики могли быть получены за счёт любопытства или неточного обещания. Проверьте полезные переходы, время содержательного взаимодействия, жалобы и удовлетворённость. Улучшение промежуточной метрики не равно улучшению читательского опыта.

Словарь основных понятий

AI / ИИ - область методов и систем, выполняющих задачи, связанные с восприятием, прогнозированием, рассуждением и выбором действий.

ML - машинное обучение: настройка моделей по данным. Deep learning - его направление, использующее многослойные нейронные сети.

Baseline - простое исходное решение, с которым сравнивают более сложные варианты.

Признак - входная характеристика объекта. Метка - известный ответ в обучающем примере. Параметр - настраиваемая величина модели. Гиперпараметр - настройка процедуры или архитектуры.

Loss - функция потерь, используемая при обучении. Метрика - показатель оценки; она может отличаться от оптимизируемой функции.

Validation - данные или процедура выбора решения. Test - независимая заключительная оценка выбранного решения.

Overfitting - переобучение. Underfitting - недообучение. Data leakage - использование информации, которая не должна быть доступна при оценке или реальном прогнозе.

Embedding - векторное представление объекта. Token - элемент последовательности, обрабатываемой языковой моделью.

Transformer - архитектура с механизмом внимания. LLM - большая языковая модель. Foundation model - предобученная модель, которую можно адаптировать к разным задачам.

Pretraining - предварительное обучение. Fine-tuning - дополнительное обучение параметров. In-context learning - использование примеров и контекста при формировании ответа без обычного обновления весов.

RAG - генерация с опорой на найденные внешние материалы. Reranking - уточнение порядка уже отобранных кандидатов.

Hallucination - неподтверждённый или неверный результат, представленный правдоподобно. Grounding - связывание ответа с доступными основаниями или наблюдениями.

Agent - система, в которой модель участвует в выборе действий и использовании инструментов. Workflow - заранее организованная последовательность этапов.

RL - обучение с подкреплением. Reward - награда. Policy - политика выбора действий.

OCR - распознавание текста на изображении. IDP - интеллектуальная обработка документов. NER - выделение именованных сущностей. ASR - автоматическое распознавание речи. TTS - синтез речи по тексту.

MLOps - практики воспроизводимой разработки, выпуска и сопровождения моделей. Drift - изменение данных либо отношений между данными и результатом.

Prompt injection - попытка через входной контент навязать приложению неразрешённые инструкции. Human-in-the-loop - участие человека в существенном этапе принятия или проверки решения.

Навигатор по темам

Основы и постановка задач - главы 01-03. Данные, классическое обучение и перенос знаний - главы 04-07. Нейронные сети, зрение, языковые модели и поиск по документам - главы 08-11.

Генерация изображений, речь, рекомендации и обучение с подкреплением - главы 12-15. Постановка запросов, инструменты, данные и оценка - главы 16-19. Эксплуатация, надёжность, ответственность и выбор проекта - главы 20-24. Научные и общественные применения - глава 25.

После глав размещены практикум с ответами, словарь, источники и выходные сведения.

Источники и дальнейшее чтение

Источники проверены 30 октября 2026 года. Ссылки [1]-[18] указывают на работы и документацию, по темам пособия. Страницы документации могут обновляться со временем.

[1] Stanford HAI. The 2026 AI Index Report. Сводный обзор развития ИИ и ограничений оценки возможностей.
https://hai.stanford.edu/ai-index/2026-ai-index-report

[2] Scikit-learn. Metrics and scoring: quantifying the quality of predictions. Определения метрик и условия их применения.
https://scikit-learn.org/stable/modules/model_evaluation.html

[3] Scikit-learn. Common pitfalls and recommended practices. Разделение данных, преобразования и утечки.
https://scikit-learn.org/stable/common_pitfalls.html

[4] Scikit-learn. Ensembles: Gradient boosting, random forests, bagging, voting, stacking.
https://scikit-learn.org/stable/modules/ensemble.html

[5] Vaswani A. et al. Attention Is All You Need. 2017.
https://arxiv.org/abs/1706.03762

[6] Devlin J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2018.
https://arxiv.org/abs/1810.04805

[7] Brown T. B. et al. Language Models are Few-Shot Learners. 2020.
https://arxiv.org/abs/2005.14165

[8] Ouyang L. et al. Training language models to follow instructions with human feedback. 2022.
https://arxiv.org/abs/2203.02155

[9] Rafailov R. et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. 2023.
https://arxiv.org/abs/2305.18290

[10] Hu E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. 2021.
https://arxiv.org/abs/2106.09685

[11] Radford A. et al. Learning Transferable Visual Models From Natural Language Supervision. 2021.
https://arxiv.org/abs/2103.00020

[12] Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. 2020.
https://arxiv.org/abs/2005.11401

[13] Anthropic. Building effective agents. 19.12.2024. Архитектурное различие заданных процессов и агентов; конкретные инструменты с момента публикации изменились.
https://www.anthropic.com/research/building-effective-agents

[14] DeepSeek-AI et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. 2025; версия 2 от 04.01.2026.
https://arxiv.org/abs/2501.12948

[15] Ho J., Jain A., Abbeel P. Denoising Diffusion Probabilistic Models. 2020.
https://arxiv.org/abs/2006.11239

[16] Lipman Y. et al. Flow Matching for Generative Modeling. 2022.
https://arxiv.org/abs/2210.02747

[17] NIST. Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile. NIST AI 600-1. 2024.
https://doi.org/10.6028/NIST.AI.600-1

[18] Google DeepMind. AlphaFold. Обзор специализированных моделей предсказания биомолекулярных структур.
https://deepmind.google/science/alphafold/

Выходные сведения

Погружение в AI. Технологии, методы и практика искусственного интеллекта.

Учебное пособие. 2026 год.

Учебные примеры и инженерные рекомендации не являются отчётами о внедрении в конкретной организации.

Обложка и схемы: векторная графика. Композиция соединяет книгу как носитель знания и сеть связей как образ вычисления. Схемы являются условными учебными моделями.

© 2026 Анцибор А.В.

Составление и оформление пособия. Права на использованные первоисточники принадлежат их правообладателям.